Momento de Retroalimentación: Módulo 2 Implementación de una técnica de aprendizaje máquina sin el uso de un framework. (Portafolio Implementación)

María Fernanda Pérez Ruiz

A01742102

Cargué las librerias necesarias para correr el modelo

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
```

Importé el archivo de Valhalla23.csv para visualizar la información con la que voy a trabajar. Obteniendo las columnas de grados en "Celsius" y "Valks". Siendo mi base de datos de 100 filas.

```
file_path = '/content/Valhalla23.csv'
data = pd.read_csv(file_path)

print(data.head(15))
len(data)
```

```
     Celsius    Valks
0   61.4720 -139.740
1   70.5790 -156.600
2   -7.3013   73.269
3   71.3380 -165.420
4   43.2360  -75.835
5  -10.2460   83.437
6    7.8498   24.680
7   34.6880  -55.108
8   75.7510 -182.820
9   76.4890 -183.460
10  -4.2387   61.973
11  77.0590 -171.990
12  75.7170 -175.830
13  28.5380  -30.998
14  60.0280 -142.490
100
```

Separé mis datos en 80% para entrenamiento y 20% para prueba

```
np.random.seed(40)
train_size = int(0.8 * len(data))
```

Mezclé los datos y despues, extraje las características "Celsius" y las etiquetas "Valks" para cada conjunto.

```
data_shuffled = data.sample(frac=1).reset_index(drop=True)
train_data = data_shuffled[:train_size]
test_data = data_shuffled[train_size:]

X_train = train_data['Celsius'].values
y_train = train_data['Valks'].values
X_test = test_data['Celsius'].values
y_test = test_data['Valks'].values
```

Procedí a implementar un modelo de regresión lineal utilizando descenso de gradiente para ajustar la relación entre las temperaturas (grados) en Celsius y Valks. Y despues calculé el error cuadrático medio (MSE), lo hicé con 10,000 iteraciones para evaluar el rendimiento del modelo, y finalicé con las graficas para visualizar tanto las predicciones frente a los datos reales como la evolución del costo."

```
def compute_cost(X, y, m, b):
    n = len(y)
    cost = np.sum((m * X + b - y) ** 2) / (2 * n)
```

```
        return cost

    learning_rate = 0.0001
    m = 0.0
    b = 0.0
    iterations = 10000

    cost_history = []

    for i in range(iterations):
        y_pred = m * X_train + b
        dm = (-2/len(X_train)) * np.sum(X_train * (y_train - y_pred))
        db = (-2/len(X_train)) * np.sum(y_train - y_pred)
        m = m - learning_rate * dm
        b = b - learning_rate * db
        cost = compute_cost(X_train, y_train, m, b)
        cost_history.append(cost)

    y_test_pred = m * X_test + b

    test_cost = compute_cost(X_test, y_test, m, b)


    plt.figure(figsize=(12, 5))
    plt.subplot(1, 2, 1)
    plt.scatter(X_test, y_test, color='blue', label='Datos reales')
    plt.plot(X_test, y_test_pred, color='red', label='Predicciones')
    plt.xlabel('Celsius')
    plt.ylabel('Valks')
    plt.title('Predicciones vs datos reales')
    plt.legend()
    plt.subplot(1, 2, 2)
    plt.plot(range(iterations), cost_history, color='green')
    plt.xlabel('Iteraciones')
    plt.ylabel('Costo')
    plt.title('Evolución del costo en el entrenamiento')
    plt.tight_layout()
    plt.show()


    print("Pendiente (m):",m, "\n")
    print("Intersección (b):", b , "\n")
    print("Costo final (Error cuadratico medio (mse)):",cost_history[-1],"\n" )
    print("Costo (mse):",test_cost,"\n" )
    print("Ecuación del modelo de regresión lineal:", "Valks =", m , "x" , "Celcius + ", b)
```

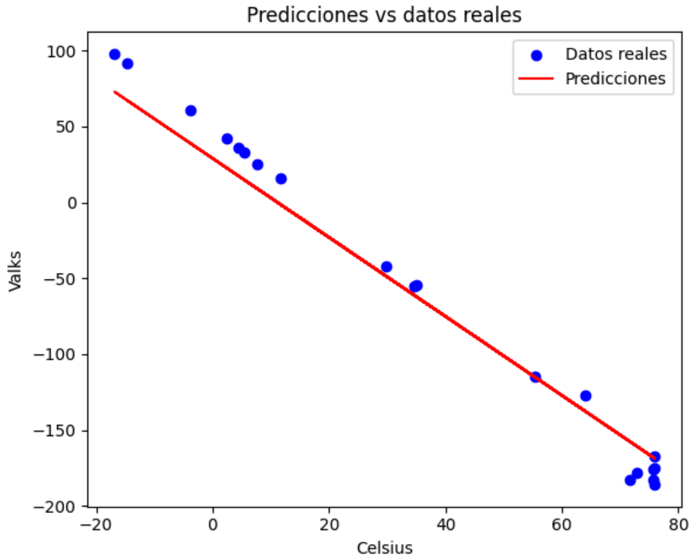

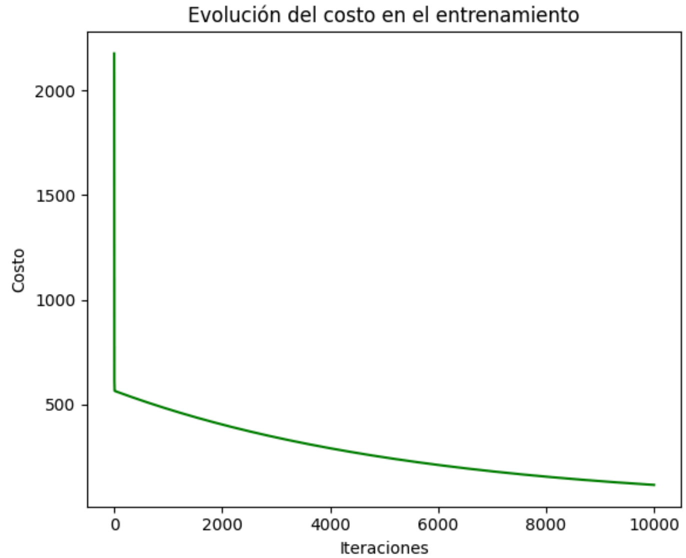


```
Pendiente (m): -2.602659841340007

Intersección (b): 29.046798995179003

Costo final (Error cuadratico medio (mse)): 114.88337101823215

Costo (mse): 128.11021590429146

Ecuación del modelo de regresión lineal: Valks = -2.602659841340007 x Celcius +  29.046798995179003
```

En la primera grafica 'Predicciones vs datos reales' los puntos azules son los datos reales, y la linea roja es la representación de las predicciones del modelo de regresión lineal. Como vemos la linea roja se ajusta de manera adecuada, no perfecta, pero adecuada ya que la